



Atividade 2: Implementação de Framework "LLM-as-a-Judge" e Persistência em Banco de Dados Relacional

1. Contexto e Objetivo

A avaliação manual de milhares de instâncias em domínios como Direito e Medicina é inviável em escala industrial. No entanto, as métricas clássicas (ROUGE/BLEU) são insuficientes por serem puramente lexicais.

Nesta etapa, as equipes deverão implementar uma solução mais sofisticada para avaliar as respostas fornecidas pelos modelos selecionados na Atividade 1. O objetivo é consolidar os resultados em uma infraestrutura robusta, utilizando o paradigma **LLM-as-a-Judge** para auditar a acurácia técnica, segurança clínica e fundamentação jurídica, armazenando todo o ciclo de vida dos dados em um ambiente relacional.

2. Repositórios de Dados e Links de Acesso

As equipes mantêm os domínios e datasets da atividade anterior:

- ⚖️ **Jurídico (Equipes 1, 3 e 4):** maritaca-ai/oab-bench (Abertas) e eduagarcia/oab_exams (Múltipla Escolha).
 - 🩺 **Médico (Equipes 2 e 5):** [Itaymanes K-QA](https://itaymanes.com/kqa) (Abertas) e [USMLE com Gabarito](https://usmle.com/gabarito) (Múltipla Escolha).
-

3. Etapas Previstas

1. **Consolidação e Modelagem de Dados:** Organizar o dataset original e as **respostas geradas pelos modelos selecionados e testados na Atividade 1.**
2. **Arquitetura PostgreSQL:** Modelar e implementar um banco de dados relacional para armazenar:
 - O dataset original (perguntas e gabaritos).
 - As respostas da Atividade 1 (identificando o modelo utilizado).
 - As avaliações do Juiz (notas e o **Chain-of-Thought** explicativo).
3. **Execução do Juiz-IA:** Implementar o pipeline Input -> Referência -> Prompt do Juiz -> Output utilizando outros modelos, se possível, com melhor capacidade que os utilizados na atividade 1.

4. **Análise de Dados via SQL:** Extrair métricas diretamente do banco para analisar a correlação (Spearman) entre o Juiz e o Gabarito Humano.

4. Artefatos e Regras de Entrega

- 17

Data Limite: 14 de maio de 2026 (Quinta-feira), até as 12h00.
- **Repositório GitHub:** Pasta Atividade_2 contendo scripts Python, prompts e o **arquivo de backup (.sql ou .dump) do PostgreSQL**.
 - **Tutorial em PDF:** Deve incluir instruções detalhadas de **restore** do banco de dados, exemplos de queries utilizadas e a metodologia da rubrica.
 - **Vídeo de Apresentação: Duração mínima de 10 minutos e máxima de 20 minutos.** O link deve constar no README.md. Cada membro deve demonstrar sua parte na engenharia do banco ou na calibração do Juiz.
 - **Instruções de Restore:** É mandatório que o tutorial permita ao professor recriar o ambiente de dados localmente para auditoria das notas.

5. Barema de Avaliação (Critérios de Nota)

Critério	Descrição	Peso
Modelagem e PostgreSQL	Qualidade do esquema relacional, integridade dos dados e facilidade de restore.	30%
Engenharia de Rubricas	Rigor técnico e criatividade na definição das escalas de 1 a 5 para o Juiz.	20%
Pipeline de Avaliação	Implementação do fluxo de julgamento e extração do Chain-of-Thought.	25%
Análise de Resultados	Profundidade da discussão estatística baseada nos dados do banco.	15%
Vídeo e Documentação	Clareza na exposição e organização dos artefatos no GitHub.	10%

Nota do Professor: A inclusão do PostgreSQL visa simular um ambiente real de produção onde a rastreabilidade é fundamental. Não basta avaliar; é preciso saber *quem* avaliou, *quando* e sob qual *lógica explicativa*.

APÊNDICE



Esquema de Banco de Dados Sugerido (DDL)

As equipes podem executar o código abaixo diretamente no console do **PostgreSQL** ou via **pgAdmin**:

SQL

-- 1. Tabela de Metadados dos Modelos (Candidatos e Juizes)

```
CREATE TABLE modelos (  
  id_modelo SERIAL PRIMARY KEY,  
  nome_modelo VARCHAR(100) NOT NULL, -- Ex: 'Llama-3-8B-4bit', 'GPT-4o'  
  versao VARCHAR(50),  
  parametro_precisao VARCHAR(20) -- Ex: 'INT4', 'FP16', 'N/A'  
);
```

-- 2. Tabela de Datasets

```
CREATE TABLE datasets (  
  id_dataset SERIAL PRIMARY KEY,  
  nome_dataset VARCHAR(100) NOT NULL, -- Ex: 'OAB_Exams', 'K-QA'  
  dominio VARCHAR(50) NOT NULL -- Ex: 'Jurídico', 'Médico'  
);
```

-- 3. Tabela de Perguntas (O Dataset Original)

```
CREATE TABLE perguntas (  
  id_pergunta SERIAL PRIMARY KEY,  
  id_dataset INTEGER REFERENCES datasets(id_dataset),  
  enunciado TEXT NOT NULL,  
  resposta_ouro TEXT NOT NULL, -- Gabarito oficial  
  metadados JSONB -- Para guardar info extra como 'especialidade' ou 'ano'  
);
```

-- 4. Tabela de Respostas da Atividade 1 (Modelos Candidatos)

```
CREATE TABLE respostas_atividade_1 (  
  id_resposta SERIAL PRIMARY KEY,  
  id_pergunta INTEGER REFERENCES perguntas(id_pergunta),  
  id_modelo INTEGER REFERENCES modelos(id_modelo),  
  texto_resposta TEXT NOT NULL,  
  tempo_inferencia_ms FLOAT,
```

```

    data_geracao TIMESTAMP DEFAULT CURRENT_TIMESTAMP
);

-- 5. Tabela de Avaliações da Atividade 2 (O Juiz)
CREATE TABLE avaliacoes_juiz (
    id_avaliacao SERIAL PRIMARY KEY,
    id_resposta_ativa1 INTEGER REFERENCES respostas_atividade_1(id_resposta),
    id_modelo_juiz INTEGER REFERENCES modelos(id_modelo),
    nota_atribuida INTEGER CHECK (nota_atribuida BETWEEN 1 AND 5),
    chain_of_thought TEXT NOT NULL, -- O raciocínio explicativo do Juiz
    data_avaliacao TIMESTAMP DEFAULT CURRENT_TIMESTAMP
);

```



Exemplo de Query para Análise (Relatório)

Para que as equipes possam calcular a performance média e extrair os dados para o cálculo de correlação, elas podem usar uma query como esta:

SQL

```

SELECT
    d.nome_dataset,
    m_cand.nome_modelo AS candidato,
    m_juiz.nome_modelo AS juiz,
    AVG(a.nota_atribuida) AS media_notas,
    COUNT(a.id_avaliacao) AS total_avaliado
FROM avaliacoes_juiz a
JOIN respostas_atividade_1 r ON a.id_resposta_ativa1 = r.id_resposta
JOIN perguntas p ON r.id_pergunta = p.id_pergunta
JOIN datasets d ON p.id_dataset = d.id_dataset
JOIN modelos m_cand ON r.id_modelo = m_cand.id_modelo
JOIN modelos m_juiz ON a.id_modelo_juiz = m_juiz.id_modelo
GROUP BY d.nome_dataset, candidato, juiz;

```



Recomendações para os Alunos

- **JSONB para Metadados:** Recomendo o uso do tipo JSONB na tabela de perguntas para que as equipes possam guardar chaves específicas de cada dataset (ex:

{"alternativa_correta": "A"} para múltipla escolha ou {"especialidade": "Cardiologia"} para o K-QA) sem precisar alterar a estrutura da tabela.

- **Backup:** Lembrem os alunos de usar o comando `pg_dump` para gerar o arquivo que será entregue. O comando padrão seria: `pg_dump -U nome_usuario -d nome_banco -f backup_atividade_2.sql`
- **Restore:** O tutorial de entrega deve ser claro. Um comando simples como `psql -U usuario -d novo_banco -f backup_atividade_2.sql` deve ser suficiente para recriar todo o experimento.

Com este esquema, o projeto ganha um nível de **rastreabilidade profissional**.

Templates de Partida para as Equipes

Para as Equipes do Domínio Jurídico (J1 e J2)

Este prompt foca na fidelidade à legislação brasileira e na detecção de "alucinações normativas" (quando o modelo inventa leis).

Prompt do Juiz Jurídico:

[PERSONA]

Você é um Desembargador e Professor Doutor em Direito com vasta experiência em exames da OAB. Sua tarefa é avaliar a resposta de uma IA (candidata) a uma questão jurídica.

[CONTEXTO]

Pergunta: {pergunta_oab}

Gabarito (Resposta Ouro): {resposta_ouro}

Resposta da IA a ser avaliada: {resposta_modelo_edge}

[RUBRICA DE AVALIAÇÃO]

- **Nota 1:** Resposta incorreta, cita leis inexistentes ou confunde institutos básicos.
- **Nota 2:** Conclusão correta, mas a fundamentação é vaga ou cita artigos de lei errados.
- **Nota 3:** Resposta correta e bem fundamentada, mas falta clareza ou omite detalhes importantes do gabarito.
- **Nota 4:** Resposta excelente, alinhada ao gabarito, com fundamentação legal precisa.
- **Nota 5:** Resposta excepcional, fundamentada, cita jurisprudência relevante (STF/STJ) e demonstra raciocínio jurídico mestre.

[INSTRUÇÕES DE SAÍDA]

Analise a resposta da IA comparando-a com o Gabarito. Ignore o tamanho do texto; foque na precisão do Direito brasileiro.

Forneça o veredito no formato:

RACIOCÍNIO: <explique por que a nota foi dada>

NOTA: <apenas o número de 1 a 5>

Para as Equipes do Domínio Médico (M1 e M2)

Este prompt é desenhado para ser implacável com erros de segurança e dosagens, priorizando

a vida do paciente sobre a fluidez do texto.

Prompt do Juiz Médico:

[PERSONA]

Você é um médico cardiologista sênior com especialização em diretrizes clínicas internacionais (AHA/SBC). Avalie a conduta clínica proposta por um sistema de IA.

[CONTEXTO]

Pergunta/Caso Clínico: {pergunta_medica}

Resposta de Referência (Gold Standard): {resposta_ouro}

Resposta da IA a ser avaliada: {resposta_modelo_edge}

[RUBRICA DE AVALIAÇÃO]

5. **Nota 1:** ERRO CRÍTICO. Recomenda conduta perigosa, dosagem letal ou ignora sinais vitais clássicos.
6. **Nota 2:** Resposta tecnicamente correta na conclusão, mas omite passos vitais de segurança ou exames obrigatórios.
7. **Nota 3:** Resposta correta, alinhada à conduta padrão, mas carece de detalhes sobre manejo a longo prazo.
8. **Nota 4:** Resposta muito boa, seguindo as diretrizes clínicas e demonstrando bom raciocínio fisiopatológico.
9. **Nota 5:** Resposta perfeita, idêntica ou superior ao Gold Standard em clareza e precisão farmacológica.

[INSTRUÇÕES DE SAÍDA]

Seja rigoroso. Se houver erro de medicação ou diagnóstico diferencial, a nota deve ser 1 ou 2, independentemente da qualidade da escrita.

Forneça o veredito no formato:

REASONING: <justificativa técnica detalhada>

SCORE: <apenas o número de 1 a 5>



Dicas Adicionais para as Equipes

2. **Língua do Juiz:** Se vocês utilizarem o **Llama-3-70B** ou **GPT-4o**, o Juiz funciona bem em português para o Direito. No entanto, para o domínio médico (K-QA), recomendo manter o prompt do juiz em **inglês**, pois a maior parte do treinamento científico desses modelos ocorre nesse idioma, reduzindo erros de interpretação.
3. **Amostragem:** Como vocês têm equipes de 6 a 7 pessoas, cada membro pode "auditar" manualmente 20 avaliações feitas pelo Juiz-IA para verificar se ele está sendo "justo". Isso é o que chamamos de **Meta-Avaliação**.
4. **Parsing:** Usem o comando `split("NOTA:")[1].strip()` no Python para capturar apenas o número e transformar em um dado quantitativo para o seu relatório final.

Com esses templates, as equipes já podem carregar seus arquivos JSON/CSV da Atividade 1 e iniciar o processo de julgamento.

Para entender como o banco de dados PostgreSQL suporta a análise de correlação estatística,

precisamos visualizar o banco não apenas como um depósito, mas como um motor que alinha **duas perspectivas diferentes** sobre a mesma pergunta.

A "correlação" aqui mede o quanto o **Juiz-IA** concorda com o **Gabarito Humano** (Resposta Ouro). Se o Juiz dá nota 5 sempre que o modelo acerta o gabarito, e nota 1 sempre que ele erra, temos uma correlação perfeita.

1. A Conexão Estrutural (O "JOIN" da Verdade)

O esquema relacional permite que você extraia, em uma única linha de tabela, o que o humano disse que é certo e o que a IA julgou. O "segredo" está na rastreabilidade das chaves estrangeiras:

- `perguntas.resposta_ouro` → O que o **humano** definiu como verdade.
- `avaliacoes_juiz.nota_atribuida` → O que o **Juiz-IA** definiu como qualidade.

2. Mecânica da Correlação com Exemplos

Vamos analisar dois cenários práticos que as equipes enfrentarão:

Cenário A: Questões de Múltipla Escolha (OAB / USMLE)

Neste caso, a correlação é binária no lado humano (Certo ou Errado).

10. **Dado do Banco:** `id_pergunta: 101, resposta_ouro: "A"`.
11. **Resposta à Atividade 1:** O modelo gerou um texto longo que termina em "Portanto, a opção correta é A".
12. **Avaliação do Juiz:** Leu o texto e deu **Nota 5**.
13. **Análise:** Aqui, convertemos o Gabarito Humano para "5" (pois o modelo acertou). Como o Juiz também deu 5, a correlação é alta.

Cenário B: Questões Abertas (K-QA / Médicas)

Aqui a correlação é mais sutil, comparando a "distância" entre as opiniões.

ID Pergunta	Resposta Ouro (Humano)	Resposta Modelo (Ativ. 1)	Nota do Juiz (Ativ. 2)	Realidade Técnica
50	Prescrever 5 mg de varfarina	Sugeriu 50mg de varfarina	Nota 1	O juiz detectou erro fatal
51	Repouso e hidratação	Sugeriu beber muita água	Nota 4	O juiz aceitou a paráfrase

3. O Cálculo Matemático: Correlação de Spearman

Como as notas do Juiz (1 a 5) são dados **ordinais** (possuem uma ordem, mas não necessariamente uma distância matemática exata entre elas), a métrica ideal que as equipes devem usar é o **Coefficiente de Correlação de Spearman** (ρ).

A fórmula que o script Python da equipe executará após puxar os dados do Postgres é:

$$\rho = 1 - \frac{\sum d_i^2}{n(n^2 - 1)}$$

Onde:

5. d_i : É a diferença entre a nota do Juiz e a nota do Gabarito Humano para cada pergunta.
6. n : É o número total de questões avaliadas.

4. Exemplo de Implementação via Query + Python

As equipes utilizarão o PostgreSQL para preparar o terreno e o Python para o cálculo final:

Python

```
import pandas as pd
from scipy.stats import spearmanr
import psycopg2

# 1. Extração dos dados via SQL
query = """
SELECT p.resposta_ouro, r.texto_resposta, a.nota_atribuida
FROM avaliacoes_juiz a
JOIN respostas_atividade_1 r ON a.id_resposta_ativa1 = r.id_resposta
JOIN perguntas p ON r.id_pergunta = p.id_pergunta;
"""

df = pd.read_sql(query, conn)

# 2. Transformação (Ex: Converter Gabarito em nota 1 ou 5 para comparar)
# Se o modelo acertou a letra do gabarito, ganha 5, senão 1.
df['nota_humana'] = df.apply(lambda x: 5 if x['resposta_ouro'] in x['texto_resposta'] else 1, axis=1)

# 3. O Cálculo da Correlação
correlation, p_value = spearmanr(df['nota_humana'], df['nota_atribuida'])

print(f"A correlação entre o Juiz e o Gabarito é: {correlation:.2f}")
```

O que o resultado diz para a equipe:

- $\rho \approx 1.0$: O Juiz de vocês é perfeito e substitui o humano.
- $\rho \approx 0.0$: O Juiz está dando notas aleatórias (prompt ruim).
- $\rho < 0$: O Juiz está "confuso" (dando notas altas para respostas erradas).



Guia de Execução Final para as Equipes

1. O Fluxo de Dados no PostgreSQL

O sucesso da atividade depende de o banco de dados refletir fielmente o experimento. Certifiquem-se de que a tabela `avaliacoes_juiz` esteja populada não apenas com a nota, mas com o **Chain-of-Thought**. É esse texto explicativo que permitirá auditar se o Juiz está alucinando ou sendo rigoroso.

2. Cálculo da Correlação na Prática

Lembrem-se: a correlação de Spearman varia de **-1 a 1**.

- **0.7 a 1.0**: Forte alinhamento. O juiz "pensa" como o gabarito humano.
- **0.3 a 0.6**: Alinhamento moderado. Talvez a rubrica precise ser mais específica.
- **Abaixo de 0.3**: O Juiz e o Humano estão discordando frontalmente. **Isso é um achado científico valioso!** Expliquem o porquê no relatório (ex: o Juiz é atualizado demais para um gabarito antigo ou vice-versa).

3. Checklist para o Backup do Banco (.sql)

Antes de gerar o arquivo .sql para entrega no GitHub, verifiquem:

14. ☐ O banco contém os dados de **todos** os membros da equipe?
15. ☐ As chaves estrangeiras estão preservadas?
16. ☐ O arquivo de backup inclui o comando `CREATE TABLE`, ou vocês forneceram o script DDL separadamente?
17. ☐ As instruções de restore no tutorial foram testadas em um computador "limpo"?



Dicas para o Vídeo de 10 a 20 Minutos

Como vocês são 6 ou 7 alunos, a organização é chave. Sugiro a seguinte divisão de tempo:

7. **Intro (2 min)**: Apresentação da equipe e escolha do Modelo Juiz.
8. **Dados e SQL (4 min)**: Demonstração do esquema no Postgres e uma query de agregação funcionando.
9. **Rubricas e Prompts (4 min)**: Explicação da lógica de avaliação (por que nota 1 e por que nota 5?).
10. **Resultados e Estatística (6 min)**: Apresentação dos gráficos de correlação e análise de casos onde o Juiz falhou.
11. **Conclusão (4 min)**: Lições aprendidas sobre o paradigma *LLM-as-a-Judge*.

Barema de Excelência

Sugiro que não busquem apenas a correlação alta. Deve ser dada importância à **Análise de Erros**. Se o Juiz deu nota 5 para uma resposta medicamente perigosa, e vocês conseguiram identificar isso através de uma query SQL e propor um ajuste na rubrica, isso demonstra que a equipe está atendendo ao objetivo da atividade.

Lembrete Final: A entrega é dia **14 de maio**, quinta-feira, até o meio-dia. Não deixem o pg_dump para a última hora!