



Atividade 3: Avaliação de Impacto de Recuperação Avançada (RAG) e Resolução Temporal em Domínios de Alta Especialidade

1. Contexto e Objetivo

Um dos grandes limites dos modelos de linguagem locais ou de menor escala testados na Atividade 1 é o conhecimento estático e a tendência a alucinações fáticas em dados muito específicos. Além disso, a **temporalidade** (leis modificadas, novas decisões de tribunais superiores ou consensos médicos atualizados) pode tornar obsoletos os pesos internos de um modelo congelado.

O objetivo desta atividade é: evoluir o ecossistema construído pelas equipes aplicando o conceito de **RAG-as-a-Judge** e **RAG Base**. Cada equipe deverá implementar uma arquitetura de Geração Aumentada por Recuperação (RAG) para municiar os **mesmos modelos selecionados e testados na Atividade 1** com documentos técnicos altamente atualizados, medindo o impacto fático e temporal nas respostas (tanto abertas quanto de múltipla escolha).

2. Repositórios de Dados e Temas

As equipes mantêm estritamente os mesmos conjuntos de dados e a distribuição de componentes já consolidada:

- ⚖️ **Domínio Jurídico (Equipes 1, 3 e 4):** Datasets J1 ([oab-bench](#)) e J2 ([oab_exams](#)).
- 🩺 **Domínio Médico (Equipes 2 e 5):** Datasets M1 ([K-QA](#)) e M2 ([USMLE](#)).

3. Etapas Previstas na Atividade

Passo 1: Curadoria de Documentação Externa e Justificativa (O Cérebro do RAG)

Cada equipe deve selecionar ativamente um corpo de documentos externos em formato texto/PDF para alimentar a base de vetores do RAG.

- **Critério de Inclusão:** A equipe deve listar e justificar textualmente no relatório quais critérios utilizou para escolher tais documentos (ex: manuais de diretrizes da

SBC/AHA posteriores ao ano de corte do modelo, atualizações do Código Penal e jurisprudências do STF/STJ recentes).

- **Fator Temporalidade:** É obrigatório incluir pelo menos um conjunto de documentos que represente atualizações de conhecimento que o modelo *não possuía* nativamente em seus pesos por questões de data de corte (*knowledge cutoff*).

Passo 2: Implementação da Arquitetura RAG

Implementar um pipeline local ou via API contendo:

1. Um componente de quebra de texto (*Chunking*) e geração de *embeddings*.
2. Uma base vetorial (ex: ChromaDB, FAISS ou a própria extensão **pgvector** acoplada ao PostgreSQL já estruturado na Atividade 2).
3. Um mecanismo de busca por similaridade que capture os top-k fragmentos mais relevantes para a pergunta original do estudante.

Passo 3: Re-Inferência dos Modelos de Linguagem

Submeter as perguntas originais novamente aos mesmos modelos de linguagem da Atividade 1, mas agora incluindo no contexto do prompt os fragmentos recuperados pelo RAG.

Passo 4: Nova Avaliação Automatizada (*LLM-as-a-Judge* pós-RAG)

Utilizando o ecossistema da Atividade 2, rode novamente o seu pipeline com o modelo Juiz para avaliar as respostas geradas *com suporte do RAG*.

- **Casos de Teste:** O banco de dados PostgreSQL deve ser atualizado para permitir a comparação direta: **Nota_Juiz_Sem_RAG** contra **Nota_Juiz_Com_RAG**.
- O juiz deve usar o campo *Chain-of-Thought* para determinar se o RAG ajudou a corrigir uma alucinação ou se trouxe ruído para a resposta.

Passo 5: Análise Estatística de Evolução

Calcule os novos coeficientes de correlação de Spearman (ρ) e avalie se houve ganho estatístico de desempenho em relação ao gabarito padrão-ouro humano após a introdução da base de conhecimento.

4. Artefatos e Regras de Entrega

 **Data Limite para Upload dos Artefatos:** 10 de junho de 2026 (quarta-feira até as 12h00 (meio-dia)).  **Apresentações Presenciais:** 11 de junho de 2026 (quinta-feira, com participação obrigatória de todos os membros das equipes.)

Os representantes oficiais de cada equipe designados nas atividades anteriores realizarão a postagem na thread dedicada do Google Classroom:

- **Equipe 1:** Helena, Rafael | **Equipe 2:** Carlos, Gilson Inácio | **Equipe 3:** Fernanda Mirely, Mikaela, Victor Leonardo | **Equipe 4:** Paulo | **Equipe 5:** Marcelo West, Clelio, Sergio Santana, Hernandson Bispo.

Entregáveis no Repositório Git e Classroom:

1. **Tutorial em PDF (Consolidado):** Capa com dados do SIGAA, link do vídeo e declaração explícita de contribuições. Deve detalhar a arquitetura do RAG, os critérios de inclusão dos documentos, as queries SQL executadas e os resultados das correlações estatísticas.
2. **Atualização do Repositório GitHub:** Inclusão da pasta **Atividade_3** contendo os novos scripts Python (pipeline RAG), os prompts de sistema atualizados e o arquivo de backup estruturado (**.sql** ou **.dump**) refletindo os dados antes e depois do RAG.
3. **Vídeo Demonstrativo:** Duração mínima de 10 minutos e máxima de 20 minutos. Cada componente deve demonstrar na IDE ou no terminal a execução da sua fatia de código ou os dados correspondentes à sua curadoria. O link deve estar no README.md.

5. Barema de Avaliação (Critérios de Nota)

Critério	Descrição	Peso
Arquitetura RAG e Justificativa	Qualidade fática dos documentos escolhidos, tratamento da temporalidade e robustez técnica do componente de busca/recuperação.	30%
Pipeline e Evolução no DB	Adaptação correta do esquema relacional e scripts para comparar o desempenho dos modelos com e sem RAG.	25%
Meta-Avaliação (Juiz)	Qualidade e rigor do prompt do Juiz ao discriminar o ganho gerado pelo RAG via <i>Chain-of-Thought</i> .	20%
Análise Estatística e de Erros	Profundidade na verificação de correlação e identificação de casos onde o RAG falhou ou inseriu ruído.	15%
Apresentação Presencial e Documentação	Domínio do tema demonstrado em sala de aula por todos os componentes e organização dos arquivos.	10%



Nota de Orientação Pedagógica

Fiquem atentos para não transformar o RAG em um injetor de textos desconexos. O papel do engenheiro de IA e cientista de dados nesta fase é a **filtragem qualitativa**. Um documento mal selecionado destruirá o coeficiente de correlação do seu modelo e será punido pelo seu próprio agente juiz.

Use o conhecimento adquirido em sala de aula para arquitetar uma estratégia limpa e defensável na nossa banca presencial. Bons experimentos!